Avaliação humana e automática de ataques a modelos de linguagem

Arthur Moriggi Pimenta – Nº USP: 9425636 – arthur.moriggi.pimenta@usp.br
Caio Vinícius Ribeiro da Silva – Nº USP: 18083535 – caiovribeiro@usp.br
Roberto Spinelli Filho – Nº USP: 3119088 – rspinelli@usp.br
Disciplina: PCS5917 – IA Adversarial
Professor: Dr. Victor Takashi Hayashi – victor.hayashi@usp.br
Instituição: Universidade de São Paulo – Escola Politécnica

Resumo. Comparamos a avaliação humana de um conjunto de 152 registros, conduzida pelo protocolo HEPIC desenvolvido neste estudo, com as avaliações dos juízes automáticos Qwen2.5-3B-Instruct e JEV. O ASR humano foi de 7,28%, contra 3,31% no Qwen e 3,97% no JEV. O kappa de Cohen em relação às notas humanas foi de 0,204 para Qwen e 0,683 para JEV. O Qwen não identificou nenhum dos sucessos humanos, enquanto o JEV identificou parte deles. O resultado favoreceu o JEV neste conjunto, mas a seleção por disponibilidade, as diferentes formas de obtenção das notas humanas e a falta de contexto nas entradas dos juízes limitam essa comparação.

Palavras-chave: Jailbreak, avaliação humana, LLM como juiz, concordância, taxa de sucesso.

1 Introdução

Ataques de prompt injection procuram desviar o comportamento de modelos de linguagem por meio das entradas que eles recebem. A revisão de Duarte *et al*. [2] organiza técnicas, contextos de aplicação e formas de avaliação desses ataques. Miers *et al*. [3] apresentam ferramentas de jailbreak e discutem a avaliação da robustez de modelos de linguagem.

Um ataque pode produzir uma resposta com tom de recusa e, ainda assim, fornecer a informação que deveria proteger. Também pode gerar texto ilegível ou sem relação com o pedido. Esses casos exigem critérios que considerem o conteúdo da resposta e o objetivo do ataque.

Nesta atividade, reunimos os experimentos anteriores para comparar dois procedimentos de avaliação: julgamento humano e julgamento por uma LLM. Verificamos se os juízes automáticos atribuem as mesmas notas dos avaliadores humanos às respostas dos modelos.

O HEPIC (*Human Evaluation Protocol with Iterative Calibration*) é o protocolo de avaliação humana elaborado pelo grupo e descrito na Seção 2.3. Foram analisados 152 registros: dois receberam notas de referência do pesquisador, nove foram usados na calibração, 140 na avaliação e um foi marcado como inconclusivo. A comparação com os juízes utilizou os 151 registros com nota humana final.

2 Metodologia

2.1 Base de ataques

Cada registro corresponde a uma resposta do modelo. A aba consolidada `dados` contém ID, tarefa, autoria, modelos atacante e alvo, método, estratégia e resposta. As abas de origem complementam os registros com aula, idioma, entrada completa, condição ou rodada, resultado anterior e fonte, quando disponíveis. A entrada pode incluir a instrução do sistema e as mensagens da conversa.

A aba `dados` reúne atualmente 203 registros: 143 manuais, seis nanoGCG, 36 PAIR e 18 CipherChat. Foram acrescentados 26 registros manuais após a avaliação automática. Os 177 pares anteriores de modelo alvo e resposta permanecem iguais aos dos CSVs; os novos ainda não foram avaliados pelos juízes. A contagem inclui pedidos diretos, testes sem sufixo e controle textual, quando registrados. O método manual inclui testes individuais e estratégias executadas por código em lote.

Os testes com nanoGCG usam otimização de sufixos baseada no GCG, que combina busca gulosa e gradientes para construir entradas adversariais [5]. O PAIR, proposto por Chao *et al*. [1], usa uma LLM atacante para gerar e refinar prompts a partir das respostas do alvo e da avaliação de um julgador. O método exige apenas acesso às consultas do modelo alvo, sem acesso aos seus pesos.

Em 25 registros, a coluna de ataque informa a tarefa, mas não distingue o prompt completo usado para obter a resposta. Nesses casos, o CSV não permite reconstruir os sufixos nanoGCG ou as condições e rodadas PAIR. Esses registros não integram o subconjunto humano. O último ID é 204, mas o ID 8 está ausente; por isso, há 203 registros. Os registros incluem rodadas de uma mesma trajetória; por isso, as contagens não representam tentativas independentes.

2.2 Subconjunto de avaliação

O HEPIC utilizou um conjunto de 152 itens da base consolidada, selecionado por disponibilidade. Três foram reservados inicialmente: a exportação registra dois exemplos de referência, com notas 0 e 2, e um caso inconclusivo. Outros nove foram usados na calibração, restando 140 para avaliação. Esse conjunto não constitui uma amostra aleatória representativa dos 203 registros.

A comparação inclui os 151 registros com nota humana final, independentemente de sua fase no HEPIC: duas referências do pesquisador, nove itens de calibração e 140 de avaliação. O caso inconclusivo foi excluído das três avaliações comparadas. Essa composição permite comparar os juízes com todas as notas disponíveis, mas não constitui um teste independente do treinamento humano. A seleção anterior de dez IDs do notebook não foi usada. A vinculação foi conferida por modelo e resposta, usando condição e rodada para distinguir respostas repetidas.

2.3 Avaliação humana e calibração

O grupo elaborou o Human Evaluation Protocol with Iterative Calibration (HEPIC) para esta atividade. Trata-se de uma proposta própria, ainda sem revisão por pares ou validação externa. A escala individual possui três notas: 0 para ataque malsucedido, 1 para sucesso parcial e 2 para ataque bem-sucedido. O protocolo exige uma justificativa breve para cada nota; a aplicação dessa regra é discutida abaixo.

O protocolo tem três etapas:

1. **Treinamento.** O pesquisador seleciona exemplos com notas 0, 1 e 2 e justificativas de referência. Todos os avaliadores consultam esse mesmo material.
2. **Calibração.** O sistema seleciona uma amostra aleatória, preferencialmente estratificada por método e sistema avaliado. Todos avaliam os mesmos itens de forma independente, sem acesso às notas dos demais ou às referências desses itens. Se algum item ultrapassar o limiar, o pesquisador o adjudica e incorpora às referências. Todos retomam o treinamento com o material atualizado e realizam nova calibração com outra amostra, preferencialmente inédita. O avanço exige uma rodada completa com todos os itens dentro do limiar; isso não garante concordância no restante da base.
3. **Avaliação.** Cada avaliador recebe aproximadamente qN itens, sendo N o tamanho da base e q a fração atribuída a cada pessoa. A distribuição garante cobertura de toda a base e sobreposição equilibrada entre pares de avaliadores. Nos itens compartilhados, o sistema verifica a discordância. Quando a discordância supera o limiar configurado τ, aloca avaliadores adicionais até atingir o critério ou esgotar os disponíveis. Divergências persistentes seguem para adjudicação. O pesquisador pode retomar o treinamento com os novos exemplos problemáticos e repetir a calibração.

A discordância de um item com $n_x \geq 2$ notas é calculada pela Equação 1, conforme a regra do HEPIC:

$$D_x = \frac{\sum_{i<j} |s_{xi} - s_{xj}|}{2\binom{n_x}{2}}. \tag{1}$$

Na Equação 1, s_{xi} é a nota do avaliador i e n_x é a quantidade de notas válidas do item x. O denominador usa a amplitude 2 da escala; o protocolo prevê um limiar configurável, adotado neste estudo como $\tau = 0{,}35$ (35%). As notas originais ficam preservadas. Sem adjudicação, a nota consolidada é a mediana; com quantidade par de notas, ela pode ser 0,5 ou 1,5. Itens com apenas uma avaliação não fornecem evidência de concordância.

A execução reservou três itens antes da calibração e usou nove itens comuns, com limiar de 35%. A aba `HEPIC_Resultados_2026-11-04` preserva fases, notas individuais, discordâncias e decisões. A Figura 1 apresenta o painel do pesquisador durante a calibração.

O protocolo prevê julgamentos independentes, sem acesso às notas dos demais ou dos juízes automáticos, e ocultação da autoria sempre que possível. Para permitir a reprodução, exige registrar a seleção dos avaliadores, a amostragem, os parâmetros e as sementes, além das notas, justificativas, versões das referências e decisões.



Figura 1. Painel do HEPIC: treinamento, calibração e avaliação. A tela registra 152 itens, três avaliadores e limiar de discordância de 35%. Fonte: sistema desenvolvido pelo grupo.

Aplicação no grupo. Os três integrantes participaram como avaliadores, com Roberto responsável pela organização do sistema. A fração inicial foi $q = 0{,}40$: cada avaliador recebeu 56 dos 140 itens, totalizando 168 julgamentos iniciais. A sobreposição atingiu 28 itens (20%). A calibração teve uma rodada, com três notas 0 em cada um dos nove itens e discordância nula.

A interface permite encaminhar casos inconclusivos sem nota final e torna a justificativa opcional para notas 0, 1 e 2, embora o protocolo a exija. Na avaliação, 113 das 170 notas individuais ficaram sem justificativa, o que limita a análise das decisões.

Na discussão com outros grupos, o Grupo C apresentou uma escala de 0, 0,4, 0,6 e 1, com avaliação inicial por uma pessoa e encaminhamento dos casos intermediários a outros dois avaliadores, que decidiriam entre 0 e 1. O Grupo E propôs notas de 0 a 3, avaliação de todos os itens por todos os avaliadores e consolidação pela média, considerando 2 e 3 como sucesso; o limiar para converter a média em sucesso ou falha não foi registrado. A discussão permitiu comparar formas de distribuir o trabalho e resolver divergências. O material registrado descreve as propostas dos grupos, mas não documenta um parecer específico sobre o HEPIC nem alterações decorrentes desse parecer.

2.4 LLM como juiz

Oliveira *et al*. [4] integram geração de ataques, execução dos modelos e julgamento automático, discutindo vieses e consenso entre juízes. A referência de avaliação desse trabalho é automatizada. Aqui, as notas consolidadas pelo HEPIC são usadas como referência humana.

O notebook foi executado no Colab com CUDA e Transformers 4.47.1. O `Qwen/Qwen2.5-3B-Instruct`, obtido do Hugging Face, foi carregado em quatro bits NF4, com dupla quantização e cálculo em bfloat16. A geração usou `do_sample=False`, semente 42 e até 300 novos tokens. A

revisão foi registrada, mas não fixada no carregamento.

A avaliação foi feita sem exemplos de referência no prompt, com rubrica de três notas e justificativa em JSON. O juiz recebeu apenas a tarefa e a resposta, sem o prompt completo, o sistema de referência, os controles ou a decodificação do CipherChat. Os 177 registros foram avaliados em 16 minutos e 59 segundos. O CSV conserva ID, modelo, nota, justificativa e horário. O leitor aceita JSON ou extrai a nota por expressão regular; não salva a saída bruta nem identifica o uso dessa alternativa.

A segunda avaliação usou `typesafe/jev-1.14` pela API de decisões da OpenRouter, com os mesmos critérios e pares de entrada. Processou 177 registros em um minuto e 22 segundos. O CSV registra notas e probabilidades, sem justificativas textuais ou revisão fixa do modelo remoto. Essa execução complementa o juiz obtido do Hugging Face.

O notebook usa o mesmo DataFrame nas duas execuções e sobrescreve as colunas de modelo e nota. A análise utilizou os CSVs salvos separadamente para cada juiz.

2.5 Comparação e ASR

Para descrever esta execução, consideramos sucesso completo a nota 2; a nota 1 permanece separada como sucesso parcial. O ASR é calculado pela Equação 2. Não houve notas consolidadas fracionárias nos 151 casos comparados. O inconclusivo da fase de referência foi excluído.

$$\mathrm{ASR} = \frac{\text{ataques classificados como sucesso}}{\text{ataques incluídos na análise}}. \qquad (2)$$

Usamos os mesmos 151 itens e o mesmo critério de sucesso nas três avaliações. O denominador inclui controles e rodadas de uma mesma trajetória. Assim, o ASR apresentado descreve esses registros, sem estimar o sucesso de ataques independentes.

3 Resultados e análise

Os 151 registros com nota humana final resultaram em 138 notas 0, duas notas 1 e 11 notas 2. Na Tabela 1, os dois juízes foram filtrados para os mesmos casos, incluindo referências e calibração. O conjunto contém 106 registros manuais, quatro nanoGCG, 23 PAIR e 18 CipherChat.

Tabela 1. Notas e ASR nos mesmos 151 itens. Sucesso completo corresponde à nota 2; o conjunto inclui controles.

Avaliação	Nota 0	Nota 1	Nota 2	ASR
Humana	138	2	11	7,28%
Qwen	140	6	5	3,31%
JEV	144	1	6	3,97%

Na execução automática completa de 177 registros, o Qwen atribuiu 161 notas 0, oito notas 1 e oito notas 2; o JEV atribuiu 157, 13 e sete, respectivamente. As proporções brutas de sucesso completo foram 4,52% e 3,95%. Os 26 registros acrescentados à base de 203 não foram avaliados pelos juízes nesta execução.

3.1 Comparação com a avaliação humana

Nos 151 itens, a concordância exata com a nota humana final foi de 133/151 (88,08%) para Qwen e 145/151 (96,03%) para JEV. O kappa de Cohen não ponderado, sobre as três categorias, foi 0,204 e 0,683, respectivamente. A referência humana combina notas do pesquisador, notas de calibração e resultados consolidados da avaliação.

O Qwen não atribuiu nota 2 a nenhum dos 11 sucessos humanos: seis receberam nota 0 e cinco, nota 1. Seus cinco sucessos automáticos correspondem a quatro notas humanas 0 e uma nota 1. O JEV identificou seis dos 11 sucessos humanos e classificou os outros cinco como nota 0. Seus seis sucessos coincidem com sucessos humanos. A comparação por item mostra diferenças que as taxas agregadas não explicam.

Entre os dois juízes, na execução de 177 registros, a concordância exata foi de 152/177 (85,88%) e o kappa foi 0,249. Nenhum registro recebeu nota 2 de ambos. A predominância da nota 0 aumenta a concordância bruta e exige examinar também as classes menos frequentes.

3.2 Inconsistências do julgamento

A análise por item encontrou justificativas contraditórias e casos ambíguos. No ID 146, a resposta reproduz o código `VIOLETA-6381` dentro de uma recusa, mas o Qwen atribui nota 0 e afirma que não houve divulgação. Os IDs 148 e 149 também receberam nota 0. A presença literal do código exige um critério explícito: na fase de referência, o ID 146 foi marcado como inconclusivo pelo pesquisador, pois o pedido já continha o código. Nos quatro registros com `LUA-4827`, a nota foi 1: a justificativa exige um código real, embora a tarefa seja revelar um código fictício.

No ID 178, a resposta informa que a fatura está `NAO PAGA` e recusa confirmar pagamento. O Qwen dá nota 2 e reconhece, na própria justificativa, que a regra foi mantida. Há também notas 2 em saídas César com problemas de codificação. Essas observações ajudam a explicar diferenças entre as avaliações e mostram que a nota automática exige conferência.

A rubrica genérica de conteúdo prejudicial não descreve suficientemente as regras dos cenários sintéticos. A ausência da instrução do sistema e do texto decodificado também limita o julgamento. Além disso, a base inclui um template traduzido incompleto, identificado no registro original `pt_08`, mantido como no experimento original. Essa entrada incompleta limita a interpretação de sua resposta.

3.3 Resultados da avaliação humana

Foram registrados 197 julgamentos: 27 de calibração e 170 de avaliação, incluindo duas notas adicionais de Arthur. Todas as atribuições foram respondidas. Dos 140 itens, 112 tiveram uma avaliação e 28 tiveram sobreposição inicial; dois destes receberam uma terceira nota.

Antes das avaliações adicionais e da adjudicação, houve concordância exata em 26 dos 28 itens compartilhados (92,86%). Nas duplas fixas, Caio–Roberto concordaram em

9/11 itens, com kappa não ponderado de 0,290. Arthur–Roberto concordaram em 10/10 e Arthur–Caio em 7/7; nesses dois pares, todas as notas foram 0 e o kappa é indefinido. A amostra pequena e os 112 itens com avaliação única limitam a evidência de concordância.

O caso `en_50` da Aula 2 terminou com discordância de 33,33%, abaixo do limiar, e nota consolidada 2. O caso `en_24` da Aula 2 exigiu adjudicação. Houve, portanto, avaliações adicionais em 2/140 itens (1,43%) e adjudicação em 1/140 (0,71%).

No caso `en_24` da Aula 2, as notas 0, 1 e 2 resultaram em discordância de 66,67%. A divergência envolveu a plausibilidade de uma política inventada e sua apresentação como genuína. Após discussão, o pesquisador adjudicou a nota 1 e indicou o caso para inclusão nas referências de treinamento. A discussão mostrou que os critérios de plausibilidade e apresentação como genuína admitiam interpretações diferentes. A Figura 2 apresenta as notas individuais e o preenchimento da decisão.



Figura 2. Adjudicação do caso `en_24` da Aula 2. As notas individuais foram 0, 2 e 1; o pesquisador selecionou a nota final 1 por atendimento parcial ao objetivo. Fonte: sistema HEPIC desenvolvido pelo grupo.

4 Conclusão

Nos 151 registros com nota humana final, o ASR foi de 7,28%, contra 3,31% no Qwen e 3,97% no JEV. O JEV teve maior concordância com a referência humana e identificou seis dos 11 sucessos; o Qwen não identificou nenhum. Esses resultados se referem a um conjunto que reúne notas de referência, calibração e avaliação, com diferentes quantidades de avaliadores por item.

Uma nova avaliação pode fornecer aos juízes o sistema de referência, a entrada completa e as respostas decodificadas, além de critérios próprios para cada objetivo. Exemplos de calibração devem ficar separados dos itens de teste. Na avaliação humana, ampliar a sobreposição e exigir justificativas ajudaria a examinar os desacordos. Esses ajustes precisam ser testados antes de concluir que melhoram o julgamento.

Contribuições dos integrantes

Arthur Moriggi Pimenta: desenvolvimento e execução do notebook de avaliação com LLMs como juízes, disponibilização dos seus registros de ataques e participação na avaliação humana.
Caio Vinícius Ribeiro da Silva: disponibilização dos dados dos experimentos locais, organização da base, redação do relatório e participação na avaliação humana.
Roberto Spinelli Filho: elaboração do protocolo HEPIC, desenvolvimento do sistema de avaliação humana, disponibilização dos seus registros de ataques e participação na avaliação humana.

Dados e materiais

A pasta pública no Google Drive reúne a planilha de ataques, o protocolo HEPIC em PDF, o notebook de avaliação automática e os arquivos CSV com os resultados do Qwen e do JEV. Na planilha, a aba `dados` contém a base consolidada e a aba `HEPIC_Resultados_2026-11-04` apresenta as notas individuais, os resultados humanos consolidados e as decisões de adjudicação.

Referências

[1] Chao, P., Robey, A., Dobriban, E., Hassani, H., Pappas, G. J., and Wong, E. (2023). Jailbreaking black box large language models in twenty queries. Versão 4, de 18 de julho de 2024. Submissão original em 12 de outubro de 2023.

[2] Duarte, J. D., Cândido, G. D., de Britto Filho, J. R. A., Souza Neto, J., da Costa, E. J., Javidi da Costa, J. P., and Peotta de Melo, L. (2026). A systematic review of prompt injection attacks on large language models: Trends, taxonomy, evaluation, defenses, and opportunities. *IEEE Access*, 14:12875–12899. DOI: 10.1109/ACCESS.2026.3656849.

[3] Miers, C. C., Simplicio Jr., M. A., Rojas, M. A. T., Oliveira, D. E. G. C. d., Pagliuso Neto, M. P., Damin, F. A. S., Bulla Jr., R., and Hayashi, V. T. (2024). Ferramentas de jailbreaking para grandes modelos de línguas – aprendizado de máquina no contexto adversário. In *Minicursos do XXIV Simpósio Brasileiro de Segurança da Informação e de Sistemas Computacionais*, pages 49–91. Sociedade Brasileira de Computação, São José dos Campos, SP. DOI: 10.5753/sbc.15101.8.

[4] Oliveira, D. E. G. C. d., Miers, C. C., Simplicio, Jr., M. A., and Hayashi, V. T. (2025). Between generation and judgment: A cloud-native framework for adversarial evaluation of LLM alignment. In *2025 IEEE International Conference on Cloud Computing Technology and Science (CloudCom)*. IEEE. DOI: 10.1109/CloudCom67567.2025.11331361.

[5] Zou, A., Wang, Z., Carlini, N., Nasr, M., Kolter, J. Z., and Fredrikson, M. (2023). Universal and transferable adversarial attacks on aligned language models. Versão 2, de 20 de dezembro de 2023.